

Analyse de la variance à un facteur

Y : Variable quantitative

X : variable qualitative
"facteur"

objectif

Etudier l'effet d'une variable qualitative sur une variable quantitative

Modèle

$$Y_{ij} = \underbrace{\mu + \alpha_i}_{\mu_i} + \epsilon_{ij}$$

Effet moyen général

variable à expliquer

effet du $i^{\text{ème}}$ niveau du facteur

Erreur

- ϵ_{ij} indépendants
 - $\epsilon_{ij} \sim \mathcal{N}(0, \sigma^2)$
- $\forall i, j$

→ Facteur \bar{a} k niveaux.

↳ Pour chaque niveau i

↳ n_i : taille de l'échantillon i

↳ y_{ij} = les valeurs de y

niveau \swarrow observation \nwarrow

$$(1 \leq i \leq k)$$

$$(1 \leq j \leq n_i)$$

$$y_{ij} = \mu + \alpha_i + \varepsilon_{ij}$$

$$n = n_1 + n_2 + \dots + n_k$$
$$= \sum_{i=1}^k n_i \quad : \text{(taille totale)}$$

Conditions d'application : les variables doivent être normalement distribuées indépendantes et de même variance.

Test d'Homogénéité des variances

Comparaison des variances.

Test d'hypothèses :

$$\left\{ \begin{array}{l} H_0 : \sigma_1 = \sigma_2 = \dots = \sigma_k. \end{array} \right.$$

$$\left\{ \begin{array}{l} H_1 : \exists i \neq l \text{ tq } \sigma_i \neq \sigma_l. \end{array} \right.$$

$$\left\{ \begin{array}{l} H_0 : \text{variances égales} \end{array} \right.$$

$$\left\{ \begin{array}{l} H_1 : \text{il existe au moins deux variances qui ne sont pas égales.} \end{array} \right.$$

Statistique du test :

$$\chi^2_{k-1}$$

khi-deux (k-1) ddf

→ Commande R :

bartlett.test().

Test d'égalité des moyennes

"test" \Leftrightarrow "effet"

$$\left\{ \begin{array}{l} H_0: \mu_1 = \dots = \mu_k = \mu \\ H_1: \exists i \text{ tq } \mu_i \neq \mu \end{array} \right.$$

$$\Leftrightarrow \left\{ \begin{array}{l} H_0: \alpha_1 = \dots = \alpha_k = 0 \\ H_1: \exists i \text{ tq } \alpha_i \neq 0 \end{array} \right.$$

H_0 : Tous les niveaux ont le même effet que l'effet moyen général.

H_1 : Il existe au moins un niveau avec un effet différent de l'effet moyen général

$$\Leftrightarrow \left\{ \begin{array}{l} H_0: \text{l'effet individuel de chaque niveau est nul} \\ H_1: \text{Il existe au moins un niveau avec un effet individuel non nul} \end{array} \right.$$

$$\Leftrightarrow \left\{ \begin{array}{l} H_0: \text{absence d'effet du facteur} \\ H_1: \text{le facteur a un effet sur la variable} \end{array} \right.$$

Estimation

Sous H_0 : $\mu_1 = \dots = \mu_k = \mu$
($\alpha_1 = \dots = \alpha_k = 0$).

Modèle réduit:

$$Y_{ij} = \mu + \varepsilon_{ij}$$

Estimation

$$\hat{\mu} = \bar{Y}$$

Résidus

$$e_{ij} = Y_{ij} - \bar{Y}$$

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^{n_i} Y_{ij}$$

moyenne générale

$$\bar{Y}_i = \frac{1}{n_i} \sum_{j=1}^{n_i} Y_{ij}$$

moyenne pour chaque niveau

Équation de l'analyse de la variance.

$$SCT = SCE + SCR.$$

↓
Somme des carrés totale

•) Variation totale

Dispersion des données autour de la moyenne générale

↓
Sommes des carrés factorielle
[Inter-groupe]

•) variation due au facteur

Dispersion des moyennes de chaque niveau autour de la moyenne générale

↓
Somme des carrés résiduelle

[Intra-groupes]

•) Variation résiduelle.

Dispersion des données à l'intérieur de chaque échantillon autour de sa moyenne

$$\sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij} - \bar{y})^2 = \sum_{i=1}^k n_i (\bar{y}_i - \bar{y})^2 + \sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_i)^2$$

Tableau d'analyse de la variance

Sources de variation	Ddl	Somme des carrés	Carrés moyens	statistique
Inter - groupe. "Variation factorielle"	$k - 1$	$SCE = \sum_{i=1}^k n_i (\bar{y}_i - \bar{y})^2$	$\frac{SCE}{k-1} = \frac{1}{k-1} \sum_{i=1}^k n_i (\bar{y}_i - \bar{y})^2$	$F = \frac{\frac{SCE}{k-1}}{\frac{SCR}{n-k}}$ Fisher $(k-1) ; (n-k)$ degrés de liberté.
Intra - groupe. "Variation résiduelle"	$n - k$	$SCR = \sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_i)^2$	$\frac{SCR}{n-k} = \frac{1}{n-k} \sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_i)^2$	
Totale "Variation totale"	$n - 1$	$SCT = SCE + SCR$		

En se basant sur la statistique F et la P value affichée on prend la décision